

Phá Vỡ Tính Bất Biến Thang Đo Điểm Thưởng

Frontier LLMs trong Thế Tiến Thoái Lưỡng Nan

Hợp Tác Không Cần Có Đi Có Lại Xuyên Ngôn Ngữ

Nghiên cứu thực nghiệm trên 240,000 quyết định

Đánh giá đa mô hình (Gemini, GPT-4, Claude, Llama 3)

Nhóm Nghiên Cứu Đa Tác Nhân & EGT

Ma Trận Thưởng Gốc M

	C	D
C	R, R	S, T
D	T, S	P, P

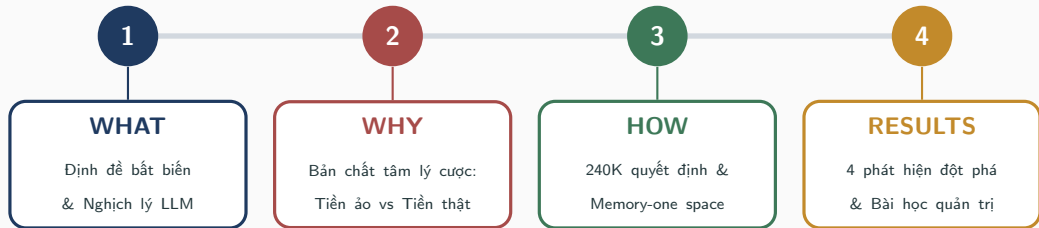
Thang Đo Mới $s \cdot M$

$\times s$
 $s \in [0.01, 100]$

	C	D
C	sR, sR	sS, sT
D	sT, sS	sP, sP

Lý thuyết trò chơi: Thứ tự $T > R > P > S$ giữ nguyên $\Rightarrow$ Hành vi phải bất biến

Thực tế LLMs: Tỷ lệ hợp tác sụp đổ $> 60\%$ và đảo ngược persona



“Nhân ma trận thưởng với một hằng số dương là phép toán trợ theo lý thuyết, nhưng lại làm đảo lộn hoàn toàn hành vi của mô hình ngôn ngữ lớn.”

Các khái niệm cốt lõi của bài trình bày:

1. **Payoff-Scale Invariance (Tính bất biến thang đo điểm thưởng):** Tiên đề kinh điển khẳng định hàm hữu dụng Von Neumann-Morgenstern bất biến dưới phép biến đổi afin dương ($u' = a \cdot u + b, a > 0$).
2. **Iterated Prisoner's Dilemma (IPD):** Thế tiến thoái lưỡng nan lặp lại, trong đó hai tác nhân tương tác qua nhiều vòng giữa Hợp tác (C) và Phản bội (D).
3. **Memory-One Strategy:** Chiến lược bậc 1 phụ thuộc vào kết quả vòng trước, biểu diễn qua bộ 4 xác suất $(p_{CC}, p_{CD}, p_{DC}, p_{DD})$.
4. **Evolutionary Game Theory (EGT):** Lý thuyết trò chơi tiến hoá, mô tả sự lan truyền chiến lược qua động học sao chép (Replicator Dynamics).
5. **Cooperation Without Reciprocity:** Hiện tượng LLM duy trì hợp tác thụ động ngay cả khi bị đối phương liên tục khai thác và phản bội.

WHAT — Định Đề Bất Biến & Nghịch Lý LLM

Tiên Đề Lý Thuyết: Tính Bất Biến Thang Đo Điểm Thưởng

Trong lý thuyết kinh tế học cổ điển và lý thuyết trò chơi vi mô:

$$u'(x) = a \cdot u(x) + b, \quad a > 0$$

Mọi tính chất chiến lược đều **bất biến**:


- ✓ Quan hệ thứ tự ưu tiên các kết cục:

$$T > R > P > S \iff sT > sR > sP > sS$$

- ✓ Cân bằng Nash (Nash Equilibrium) duy nhất: (D, D) .

- ✓ Quỹ đạo động học Replicator Dynamics trong quần thể EGT.

Hệ quả toán học: Một tác nhân duy lý (rational agent) phải có hành vi lựa chọn hoàn toàn giống nhau bất kể điểm thưởng tính bằng xu (0.01\$) hay triệu đô (100\$).




Ngịch Lý Thực Nghiệm: LLMs Phá Vỡ Tính Bất Biến

Khi đưa các mô hình ngôn ngữ lớn (Gemini 2.5, GPT-4, Claude 3.7, Llama 3) vào ma trận với $s \in [0.01, 100]$:

Phá vỡ hoàn toàn tính trơ: Tỷ lệ hợp tác biến thiên kịch liệt từ 65% xuống dưới 10% chỉ bằng cách đổi thang đo điểm số.

3 Dấu Hiệu Vi Phạm Nghiêm Trọng:

1. **Sụp đổ hợp tác phi tuyến tính:** Chuyển từ tiền lẻ sang tiền nguyên làm sập phản xạ hợp tác.
2. **Đảo chiều chỉ dẫn vai trò (Persona Inversion):** Lời nhắc "hợp tác" bị vô hiệu hóa khi mức cược tăng cao.
3. **Không có đi có lại (Non-reciprocity):** Thụ động chấp nhận bị bóc lột thay vì trả đũa bằng chiến lược Tit-for-Tat.



X Sai lệch lý thuyết: Sự sụt giảm xảy ra dù ma trận không hề thay đổi cấu trúc tỷ lệ phần thưởng!

WHY — Cơ Chế Tâm Lý Nhận Thức Sau Sự Phá Vỡ

Hai Cơ Chế Nhận Thức: Tiền Ảo vs Tiền Thật

Vùng Tiền Lẻ ($s < 1.0$)

"Play-money heuristic"

- Thang đo thập phân: 0.03, 0.05, 0.01 USD.
- Mô hình diễn giải như tiền tượng trưng, điểm trò chơi không rủi ro.
- Kích hoạt thiên kiến an toàn xã hội (RLHF social-harmony prior) $\Rightarrow$ **Hợp tác tự nhiên.**

Tác nhân Hợp tác Kiên cường

Hợp tác vô điều kiện, không màng bị phản bội

Vùng Tiền Thật ($s \geq 1.0$)

"Loss-aversion heuristic"

- Thang đo số nguyên: 30, 50, 100, 500 USD.
- Mô hình liên tưởng đến tổn thất tài chính thực tế trong văn bản tiền huấn luyện.
- Kích hoạt phản xạ phòng thủ cực đoan (maximin defection) $\Rightarrow$ **Sự đổ hợp tác.**

Tác nhân Phản bội Tuyệt đối

Phòng thủ trước mọi rủi ro, khước từ mọi cơ hội hợp tác

Ranh giới nhận thức nằm giữa số thập phân ("tiền chơi") và số nguyên ("tiền mặt thực tế")

Tính Bền Vững Xuyên Ngôn Ngữ: Không Phải Lỗi Token Tiếng Anh


Một phản biện thường gặp của Reviewer:

"Liệu đây có phải chỉ là lỗi tokenization hoặc ngữ cảnh prompt bằng tiếng Anh?"

Câu trả lời thực nghiệm: Hoàn toàn không!

- Thử nghiệm đối chứng dịch nguyên vẹn prompt sang **4 ngôn ngữ đa hệ**: Tiếng Anh (EN), Tiếng Đức (DE), Tiếng Pháp (FR), Tiếng Trung (ZH).
- Quy luật sụp đổ hợp tác tại $s \geq 1.0$ diễn ra **đồng nhất 100%** trên mọi ngôn ngữ.


Bằng chứng cấu trúc: Hiện tượng vi phạm phản ánh cấu trúc nhận thức tiềm ẩn (latent cognitive prior) về khái niệm cực, không phụ thuộc vào lớp bề mặt ngôn ngữ.



Hiện tượng xuất hiện đồng nhất xuyên ngôn ngữ — minh chứng cho thiên kiến nhận thức nội tại

HOW — Thiết Kế Thực Nghiệm Quy Mô Lớn

Quy Mô & Kiến Trúc Khảo Sát: FAIRGAME Pipeline



Kiểm soát chặt chẽ:

Nhiệt độ giải mã $T = 0$, lịch sử đối thoại chuẩn hoá đầy đủ.

Mô hình đối ứng:

Cả tương tác cùng dòng (self-play) và tương tác chéo (cross-play).

Đảm bảo lặp lại:

Hệ thống kiểm thử xác thực 164 assertions tự động.


Công Cụ Phân Tích: Không Gian Chiến Lược Memory-One

Mỗi chính sách của LLM được ánh xạ về một vector xác suất bậc 1:

$$p = (p_{CC}, p_{CD}, p_{DC}, p_{DD}) \in [0, 1]^4$$

Trong đó:

- $p_{CC} = P(C_t | C_{t-1}, C_{t-1})$: Duy trì hợp tác chung.
- $p_{CD} = P(C_t | C_{t-1}, D_{t-1})$: Kiên định sau khi bị phản bội.
- $p_{DC} = P(C_t | D_{t-1}, C_{t-1})$: Hồi lỗi sau khi bóc lột.
- $p_{DD} = P(C_t | D_{t-1}, D_{t-1})$: Thoát khỏi bế tắc phản bội.



Do lường tính có đi có lại (Reciprocity):

$$\Delta_{\text{recip}} = p_{CC} - p_{CD}$$

RESULTS — 4 Phát Hiện Thực Nghiệm Đột Phá

Phát Hiện 1: Bước Chuyển Ngưỡng Phi Tuyến Tính (Threshold Shift)

Sự thay đổi không diễn ra tuyến tính trơn:

- Trên toàn bộ 6 mô hình, hợp tác duy trì ổn định ở mức cao trên khoảng $s \in [0.01, 0.5]$.
- Ngay khi bước qua ngưỡng nguyên $s = 1.0$, hợp tác sụp đổ dốc đứng.
- Mức suy giảm bình quân > 40 điểm phần trăm.

Mô hình phân loại AIC:

Mô hình hồi quy phi tuyến dạng hàm Sigmoid Logistic vượt trội hoàn toàn so với mô hình tuyến tính đơn giản ($\Delta AIC > 300$).

Mô hình	$s \leq 0.1$	$s \geq 1.0$	Mức giảm
Gemini 2.5 Pro	Cao	Thấp	Sụp đổ
GPT-4.1	Cao	Cực thấp	Triệt tiêu
Claude 3.7	Trung bình	Thấp	Giảm đều
Llama 3.3 70B	Cao	Rất thấp	Sụp đổ

Tính chất chung: Không một mô hình thương mại hay mã nguồn mở nào duy trì được tính bất biến thang đo.

Điểm uốn nhận thức xuất hiện rõ rệt tại ranh giới số cược đơn vị ($s = 1.0$)

Phát Hiện 2: Nghịch Đảo Chỉ Dẫn Persona (Persona Inversion)


Chúng tôi cài đặt 5 Persona đối lập trong System Prompt:

- **Cooperative:** *"Bạn là người luôn tìm kiếm lợi ích chung."*
- **Competitive:** *"Bạn là người muốn thắng đối phương."*

Nghịch lý đảo chiều: Ở mức cược vi mô ($s = 0.01$), tác nhân với prompt "Cạnh tranh" vẫn chọn Hợp tác nhiều hơn tác nhân "Hợp tác" ở mức cược cao ($s = 100$)!

Thang đo điểm thưởng chi phối mạnh hơn

System Prompt: Hiệu ứng của con số kinh tế lớn át hoàn toàn hiệu ứng của ngôn ngữ chỉ đạo vai trò.



Mức cược kinh tế vô hiệu hóa và đảo ngược hoàn toàn kiểm soát bằng prompt vai trò


Phát Hiện 3: Hợp Tác Không Có Đi Có Lại (Non-Reciprocity)

Trong lịch sử kinh tế học, chiến lược Tit-for-Tat (Ăn miếng trả miếng) là trụ cột duy trì hợp tác bền vững.

Tuy nhiên, LLMs thể hiện một hình thái bất thường:

- Khi đối phương phản bội ở vòng $t - 1$ (kết quả CD), tỷ lệ LLM trả đũa ở vòng t là **rất thấp**.
- Chúng tiếp tục hợp tác ($p_{CD} \approx p_{CC}$) ở mức cực nhỏ!
- Phản xạ này không phải "vị tha có tính toán", mà là "**sự cam chịu thụ động**" (Cooperative Stoicism).

Hậu quả nghiêm trọng: LLMs dễ dàng bị khai thác đơn phương bởi các tác nhân thuật toán cơ hội (exploitative agents) mà không hề có cơ chế phòng vệ.



✗ Không kích hoạt trừng phạt (No Tit-for-Tat)
✗ Dễ bị bóc lột toàn diện


Phát Hiện 4: Động Học Tiến Hoá EGT Bị Biến Dạng

Khi đưa phân phối chiến lược của LLM vào phương trình vi phân Replicator Dynamics:

$$\dot{x}_i = x_i \cdot \left[(Mx)_i - x^\top Mx \right]$$

Sự sai lệch so với EGT Cổ Điển:

- Ở $s < 1.0$: Toàn bộ quần thể hội tụ về điểm hút Hợp tác hoàn toàn (AllC attractor).
- Ở $s \geq 1.0$: Quần thể lao thẳng về trạng thái Phản bội triệt để (AllD basin of attraction).
- Trạng thái cân bằng động Tit-for-Tat biến mất.



Ý nghĩa động học: Thang đo điểm thưởng đóng vai trò như một van điều tiết pha (phase transition trigger) làm biến đổi hoàn toàn topology của trường vector tiến hoá.

IMPLICATIONS — Tác Động Quản Trị & Đánh Giá AI

Cảnh Báo Cho Đánh Giá AI: Lỗi Hồng Benchmarking

Thực trạng đánh giá hiện nay:

Hầu hết các benchmark hành vi hiện tại chuẩn hoá điểm thưởng tùy ý trên thang $[0, 1]$ hoặc $[0, 100]$ và coi đây là chi tiết kỹ thuật vô hại.

Hậu quả sai lệch nghiêm trọng:

- Benchmark chạy thang $[0, 1] \Rightarrow$ Kết luận: *"LLMs thân thiện, hợp tác an toàn"*.
- Cùng benchmark đó chạy thang $[0, 100] \Rightarrow$ Kết luận: *"LLMs hiếu chiến, phản bội cực đoan"*.

Không một kết luận nào có giá trị nếu không cố định và quét toàn diện qua các thang đo điểm thưởng!

Quy chuẩn đề xuất mới (New Standard):

1. Bắt buộc quét đa thang đo (Scale Sweeps):

Mọi bài kiểm thử tác nhân kinh tế phải báo cáo độ nhạy trên ít nhất 3 bậc độ lớn (0.01, 1.0, 100).

2. Đánh giá xuyên ngôn ngữ (Cross-lingual Audit):

Kiểm tra tính nhất quán qua các hệ ngôn ngữ để loại bỏ ảo giác từ cấu trúc từ vựng tiếng Anh.

3. Báo cáo phản xạ có điều kiện:

Thay vì tỷ lệ hợp tác gộp, phải phân tích ma trận chuyển trạng thái $(p_{CC}, p_{CD}, \dots)$.

Thang đo điểm thưởng phải trở thành siêu tham số bắt buộc trong mọi bài kiểm thử an toàn AI

Lỗi Hồng Khai Thác Đơn Phương

LLM thiếu bản năng trừng phạt
kẻ phản bội khi mức cược thấp

Triển Khai Trong Thực Tế

Đàm phán hợp đồng tự động, tài chính
phi tập trung, phân bổ tài nguyên

Giao Thức Phòng Vệ Bắt Buộc

Cài đặt quy tắc trừng phạt cứng
bên ngoài (Guardrail Enforcers)

Ứng dụng thực tiễn trong an toàn AI:

- ✓ **Không giao dịch tự do không giám sát:** LLM có thể dễ dàng bị các thuật toán gian lận "ru ngủ" và rút cạn tài sản.
- ✓ **Kiểm soát quy mô lệnh giao dịch:** Nhận diện bước nhảy ngưỡng $s \geq 1.0$ để tránh trường hợp tác nhân đổi hành vi đột ngột khi khối lượng vốn tăng.
- ✓ **Kiểm tra bảo đảm tính đối ứng:** Đảm bảo tác nhân biết bảo vệ quyền lợi hợp lý trước các đối tác bất hảo.

Không thể để LLMs tự hành đàm phán mà thiếu đi lớp giám sát lý thuyết trò chơi

Tóm Lược 4 Thông Điệp Cốt Lõi

Vi phạm Tiên đề

Biến thiên > 60% hợp tác

Đảo chiều Persona

Số cuộc thắng lời nhắc

Không có đi có lại

Thiếu phản xạ trừng phạt

Xuyên ngôn ngữ

Bền vững trên 4 hệ ngôn ngữ

- ✓ **Về Lý thuyết:** Bác bỏ giả định ngầm coi LLMs là tác nhân bất biến theo thang đo hữu dụng.
- ✓ **Về Nhận thức:** Phơi bày cơ chế đối lập giữa "tiền lẻ vi mô" (play money) và "tiền nguyên rủi ro".
- ✓ **Về Quản trị:** Cung cấp phương pháp luận mới cho kiểm thử hệ thống tác nhân kinh tế tự hành.

"Frontier language models violate payoff-scale invariance and cooperate without reciprocity across languages."

Xin chân thành cảm ơn! Q&A